Exercício 1 — Recuperar a sequência proteica da pré-proinsulina humana

Objetivo

Neste exercício, você irá praticar:

- Pesquisa de informações em uma base de dados biológica;
- Manipulação de arquivos de texto;
- Identificação de padrões em dados;
- Limpeza de dados para utilização em um programa.

Passo a passo

1. Acesse o NCBI

Acesse o site do **National Center for Biotechnology Information (NCBI)**:

https://www.ncbi.nlm.nih.gov/

Na barra de pesquisa, altere o tipo de busca para **Protein**.

Pesquise por:

```
human insulin
```

2. Localize o registro correto

Entre os resultados, procure pelo registro:

```
insulin [Homo sapiens]
```

Abra esse resultado.

> **Dica:** `Homo sapiens` é a nomenclatura científica utilizada para a espécie humana.

3. Encontre a sequência

Dentro do registro, localize a seção que contém a sequência da proteína.

Copie o conteúdo que começa em:

```
ORIGIN
```

e termina em:

```
//
```

Observe que a sequência contém, além dos aminoácidos, outras informações como números, espaços e quebras de linha.

4. Crie um arquivo de texto

No VS Code, crie um novo arquivo e salve como:

```
preproinsulin-seq.txt
```

Cole nele a sequência obtida no NCBI.

O arquivo deverá conter a informação original, incluindo `ORIGIN`, os números, os espaços e `//`.

Bônus — Limpar a sequência programaticamente

Agora o objetivo é transformar o conteúdo original em uma sequência contendo **somente os aminoácidos**.

Esse tipo de tratamento é conhecido como **limpeza ou preparação de dados**.

5. Identifique o que precisa ser removido

Antes de escrever o código, observe o arquivo e identifique os elementos que **não fazem parte da sequência proteica**:

- `ORIGIN`;
- números das posições;
- espaços;
- quebras de linha;
- `//`.

O resultado final deverá conter apenas os caracteres que representam os aminoácidos.

6. Utilize expressão regular

Tente utilizar **Regex (expressões regulares)** para realizar a limpeza.

> **Dica:** em vez de tentar remover cada número ou espaço individualmente, pense em padrões.
> Por exemplo: “qualquer sequência de números”, “qualquer espaço” ou “qualquer quebra de linha”.

Você pode utilizar Python para:

1. Abrir o arquivo;
2. Ler seu conteúdo;
3. Aplicar as substituições necessárias;
4. Gerar a sequência limpa;
5. Verificar o resultado.

7. Confirme o tamanho da sequência

Depois de realizar a limpeza, utilize uma função do Python para descobrir a quantidade de caracteres da sequência resultante.

> **Dica:** existe uma função que recebe uma string e retorna sua quantidade de caracteres.

O resultado esperado é:

```
110
```

Checklist

- Localizei o registro `insulin [Homo sapiens]` no NCBI.
- Copiei a sequência a partir de `ORIGIN` até `//`.
- Criei o arquivo `preproinsulin-seq.txt`.
- Mantive a sequência original no arquivo.
- Identifiquei quais informações precisam ser removidas.
- Utilizei Regex para realizar a limpeza.
- Removi números, espaços, quebras de linha, `ORIGIN` e `//`.
- Obtive somente a sequência de aminoácidos.
- Verifiquei a quantidade de caracteres.
- Confirmei que a sequência possui 110 caracteres.